

1. GİRİŞ

Günümüzde bankalar ve finans kuruluşları müşteri hizmetlerini daha hızlı ve verimli hale getirmek amacıyla yapay zekâ tabanlı sistemlerden yararlanmaktadır. Özellikle müşteri destek hatlarına gelen taleplerin otomatik olarak sınıflandırılması hem operasyonel maliyetleri azaltmakta hem de müşterilere daha hızlı hizmet sunulmasını sağlamaktadır.

Bu projede doğal dil işleme yöntemleri ve büyük dil modelleri kullanılarak müşteri mesajlarının hangi bankacılık işlemi veya problemi ile ilgili olduğunun otomatik olarak belirlenmesi amaçlanmıştır. Bu sayede müşteriler doğru departmana istekleri doğrultusunda daha hızlı ulaşması beklenir. Çalışmada açık kaynak, HuggingFace verisi olan [Banking77](#) veri seti kullanılmıştır. Veri seti üzerinde önce geleneksel bir makine öğrenmesi yaklaşımı olan TF-IDF ve lojistik regresyon modeli uygulanmış, daha sonra ise derin öğrenme tabanlı DistilBERT modeli eğitilerek iki yöntem karşılaştırılmıştır.

Bu çalışma sayesinde klasik makine öğrenmesi yöntemleri ile modern transformer tabanlı dil modellerinin performansları karşılaştırılmış ve müşteri talebi sınıflandırma problemlerindeki sonuçları incelenmiştir.

2. VERİ SETİ

Bu projede HuggingFace platformunda bulunan “Banking77” veri seti kullanılmıştır. Banking77 veri seti, çevrimiçi bankacılık uygulamalarında kullanıcıların oluşturduğu müşteri destek taleplerinden meydana gelmektedir. Veri seti toplam 13083 farklı müşteri niyetini (intent) ve 77 sınıfını içermektedir. Tablo 1 verinin genel özelliklerini göstermektedir. Tablo 2 ise veri setinde yer alan bazı örnek sınıfların/özelliklerin ele aldıkları içerikleri ve konuları anlatır.

ÖZELLİK	DEĞER
Eğitim Verisi	10.003
Test Verisi	3.080
Özellik (Attribute) Sayısı	77
Veri Türü ve Dili	Müşteri Mesajları, İngilizce

Tablo 1, Veri setinin genel özellikleri

ÖRNEK SINIFLAR/ÖZELLİKLER	İÇERİK
card_arrival	Müşterinin fiziksel banka kartının henüz teslim edilmemesi, kartın kargoda olması veya teslimat sürecinin sorgulanması ile ilgili talepler.
cash_withdrawal	ATM üzerinden gerçekleştirilen para çekme işlemleriyle ilgili sorunlar, başarısız işlemler veya para çekme süreçleri hakkındaki müşteri talepleri.
failed_transfer	Banka transferinin başarısız olması, alıcıya ulaşmaması veya işlem sırasında hata alınması durumlarını içeren müşteri mesajları.
pin_blocked	Hatalı girişler nedeniyle PIN kodunun bloke olması veya kullanılamaz hale gelmesiyle ilgili talepler.
card_not_working	Banka kartının ödeme yapmaması, ATM tarafından okunmaması veya genel olarak çalışmaması ile ilgili problemler.
change_pin	Mevcut PIN kodunun değiştirilmesi, yeni PIN oluşturulması veya PIN güncelleme işlemleriyle ilgili müşteri talepleri.
verify_identity	Hesap güvenliği amacıyla müşterinin kimlik doğrulama sürecinden geçmesi, belge yüklemesi veya kimlik onayı işlemleriyle ilgili mesajlar.
transfer_fee_charged	Para transferi sırasında uygulanan ücretler, komisyon kesintileri veya beklenmeyen transfer masrafları hakkında yapılan başvurular.

Tablo 2, Veri setinde yer alan bazı örnek sınıflar ve ele aldıkları içerikler

Örnek bir kayıt/tuple aşağıdaki gibidir:

"I am still waiting on my card"

Bu kayıt veri setinde "card_arrival" etiketi ile ilişkilendirilmiştir.

Banking77 veri seti, müşteri destek sistemlerinde karşılaşılabilecek gerçek kullanıcı ifadelerini içerdiği için doğal dil işleme alanında yaygın olarak kullanılan benchmark veri setlerinden biridir.

3. YÖNTEM

Bu projede iki farklı yaklaşım kullanılmıştır.

3.1 TF-IDF VE LOJİSTİK REGRESYON

İlk aşamada geleneksel bir metin sınıflandırma yöntemi uygulanmıştır. Metin verileri doğrudan makine öğrenmesi algoritmaları tarafından kullanılamadığı için öncelikle TF-IDF yöntemi ile sayısal özelliklere dönüştürülmüştür.

TF-IDF (Term Frequency – Inverse Document Frequency) yöntemi, bir kelimenin bir doküman içerisindeki önemini ölçmek amacıyla kullanılan istatistiksel bir yöntemdir.

Bu süreçte veri içerisindeki İngilizce stop-word'ler temizlenmiştir. Özellik çıkarımı aşamasında en fazla 15.000 özellik kullanılmış ve unigram ile bigram yapıları dikkate alınmıştır. Elde edilen özellikler Lojistik Regresyon modeli ile sınıflandırma amacıyla kullanılmıştır. Pipeline yapısı içerisinde TF-IDF vektörleştirici ve lojistik regresyon sınıflandırıcısı ardışık olarak tanımlanmış olup, bu yaklaşım çalışmanın temel (baseline) modeli olarak değerlendirilmiştir.

3.2 DISTILBERT MODELİ

İkinci aşamada Transformer mimarisi kullanan DistilBERT modeli tercih edilmiştir.

DistilBERT, Google tarafından geliştirilen BERT modelinin daha hafif ve daha hızlı çalışan sürümüdür. Daha az parametre kullanmasına rağmen yüksek doğruluk oranları elde edebilmektedir.

Projede HuggingFace kütüphanesi kullanılarak *distilbert-base-uncased* modeli yüklenmiştir. Bu model, BERT mimarisine kıyasla daha hafif ve hızlı olması, buna rağmen benzer performans sunabilmesi nedeniyle tercih edilmiştir.

Eğitim sürecinde uzun müşteri şikayetleri veya konu dışı metinlerin etkisini azaltmak amacıyla veri seti üzerinde ortalama metin uzunluğu analiz edilmiş ve maksimum sekans uzunluğu 64 token olarak belirlenmiştir. Veri setindeki metinlerin büyük çoğunluğunun kısa ve kompakt yapıda olması nedeniyle daha uzun sekanslara ihtiyaç duyulmamıştır. Bu yaklaşım, hesaplama maliyetini azaltırken modelin öğrenme verimliliğini korumayı hedeflemiştir.

Model eğitimi sırasında batch size değeri 8 olarak seçilmiş, bu tercih hem donanımsal kısıtlar hem de daha stabil bir gradyan güncellemesi elde edilmesi amacıyla yapılmıştır. Weight decay parametresi 0.01 olarak uygulanarak modelin aşırı öğrenmesini (overfitting) engellemek hedeflenmiştir. Eğitim sürecinde model 10 epoch boyunca fine-tuning aşamasına tabi tutulmuş ve her epoch sonunda doğrulama seti üzerinde değerlendirme yapılmıştır. En iyi performansı veren model checkpoint'i otomatik olarak seçilerek nihai model olarak kaydedilmiştir.

Veriler, tokenizer aracılığıyla modele uygun hale getirilmiş ve üzerine eklenen sınıflandırma katmanı ile 77 sınıflı bir niyet (intent) sınıflandırma problemine dönüştürülerek yeniden eğitilmiştir. Bu aşama çalışmanın derin öğrenme tabanlı yaklaşımını oluşturmaktadır.

4. MODELİN PERFORMANSI

Modellerin performansı, eğitim sürecinde görülmeyen test verisi üzerinde değerlendirilmiştir. Değerlendirme aşamasında accuracy ve macro F1-score metrikleri kullanılmıştır. Tablo 3, iki modelin performans sonuçlarını göstermektedir.

Model	Accuracy (Doğruluk)	Macro F1-Score
TF-IDF + LR	0,8208	0,8199
DistilBERT (epoch=10, en iyi)	0,9315	0,9313

Tablo 3, Modellerin performans çıktıları

Accuracy, modelin tüm tahminler içerisindeki doğru sınıflandırma oranını ifade eder ve genel başarıyı ölçmek için kullanılan temel bir metriktir. Ancak veri setinde sınıf dağılımının dengeli olmaması durumunda tek başına yeterli olmayabileceğinden dolayı Macro F1-Score da ek bir değerlendirme metriği olarak kullanılmıştır.

Macro F1-Score, her bir sınıf için ayrı ayrı hesaplanan precision ve recall değerlerinin ortalamasını alarak tüm sınıflara eşit ağırlık veren bir performans ölçütüdür. Bu sayede modelin yalnızca baskın sınıflarda değil, tüm sınıflarda dengeli performans gösterip göstermediği değerlendirilmektedir.

Bu kapsamda TF-IDF + LR modeli 0.8208 accuracy ve 0.8199 macro F1 değeri elde ederken, DistilBERT modeli 0.9315 accuracy ve 0.9313 macro F1 değeri elde etmiştir. DistilBERT modeli 1’den 10’a kadar her epoch’u denemiş ve en başarılı sonucu epoch değeri 10’a eşit olduğunda bulmuştur. Epoch değeri bu noktadan sonra büyük bir farkla artmayı durdurmuştur.

Sonuçlar incelendiğinde DistilBERT modelinin her iki performans metriğinde de belirgin şekilde daha başarılı olduğu görülmektedir. Bu durum, Transformer tabanlı modellerin metin içerisindeki bağlamsal ilişkileri daha etkili şekilde öğrenebilmesinden kaynaklanmaktadır.

4.1. ÖRNEK ÇIKTILAR

Eğitim sonrasında en iyi performansı veren model (best checkpoint) üzerinden bazı örnek ifadeler test edilmiştir. Tablo 4’te test edilen örnekler ve model çıktıları sunulmaktadır.

KULLANICI MESAJI	TAHMİN (DistilBERT MODEL SONUCU)
my card has not arrived yet	card_arrival
cash withdrawal failed	declined_cash_withdrawal
I forgot my pin code	pin_blocked
bank transfer did not go through	failed_transfer

Tablo 4, DistilBERT model sonuç örnekleri

Model genel olarak test verisi üzerinde yüksek doğrulukla sınıflandırma yapabilmektedir. Özellikle kart teslimatı, para çekme ve transfer işlemleri ile ilgili ifadelerde başarılı performans göstermektedir.

“I forgot my pin code” örneğinde model “pin_blocked” sınıfını tahmin etmiştir. Bu örnek, semantik olarak benzer sınıflar arasındaki ayrımın bazı durumlarda zor olabileceğini göstermektedir. Doğru etiket “passcode_forgotten” olmasına rağmen modelin “pin_blocked” sınıfına yönelmesi, veri setindeki bazı sınıfların anlamsal olarak birbirine yakın olmasından kaynaklanmaktadır.

5. SONUÇ

Bu çalışmada Banking77 veri seti kullanılarak müşteri destek mesajlarının otomatik sınıflandırılması gerçekleştirilmiş ve iki farklı yaklaşım karşılaştırılmıştır: TF-IDF + Logistic Regression modeli ve DistilBERT tabanlı derin öğrenme modeli.

Elde edilen sonuçlar, DistilBERT modelinin hem Accuracy hem de Macro F1 metriklerinde belirgin şekilde daha yüksek performans sergilediğini göstermektedir. Özellikle modelin en iyi checkpoint'ı üzerinden elde edilen sonuçlar, Transformer tabanlı yaklaşımların bu problem türünde daha güçlü temsil öğrenme kapasitesine sahip olduğunu ortaya koymaktadır.

Ayrıca modelin 10 epoch boyunca eğitilmiş olması ve en iyi performans gösteren epoch'un seçilmesi, performans artışında önemli bir rol oynamıştır. Bu durum, yalnızca tek epoch ile yapılan eğitimin model kapasitesini yeterince ortaya çıkarmayabileceğini göstermektedir. (epoch=1 iken, accuracy=%82, macro f1-score=%83)

Genel olarak elde edilen bulgular, müşteri destek sistemlerinde niyet sınıflandırma problemleri için Transformer tabanlı modellerin daha yüksek potansiyele sahip olduğunu, ancak klasik makine öğrenmesi yöntemlerinin de belirli durumlarda rekabetçi sonuçlar verebildiğini göstermektedir. Gelecek çalışmalarda daha geniş hiper parametre optimizasyonu, farklı Transformer mimarileri ve veri artırma teknikleri ile performansın daha da geliştirilebileceği değerlendirilmektedir.